Informatyka, studia dzienne, I st. semestr VI

Komputerowe systemy rozpoznawania **2019/2020**
Prowadzący: dr inż. Marcin Kacprowicz poniedziałek, 12:00

Data oddania: _____ Ocena: _____

Radosław Grela 216769
Jakub Wąchała 216914

Zadanie 2: Lingwistyczne podsumowania baz danych

1. Cel

Celem zadania jest stworzenie aplikacji desktopowej, która ma za zadanie generować pewną ilość podsumowań lingwistycznych dla danej bazy danych. Aplikacja musiała umożliwić automatyczne generowanie podsumowań lingwistycznych służących do tworzenia wiadomości tekstowych na podstawie dużej bazy danych (ponad 10 tyś rekordów). [4]

2. Wprowadzenie

W ramach projektu zajmowaliśmy się analizą działania lingwistycznych podsumowań baz danych na zbiorach rozmytych. Definicja zbioru rozmytego jest istotna w naszym zadaniu i brzmi następująco:

Definicja 1. *Zbiór rozmyty A opisany na przestrzeni rozważań $\mathcal{X}$ jest zdefiniowany jako:*

$$A = \{\langle x, \mu_A(x)\rangle : x \in \mathcal{X}\}, \tag{1}$$

gdzie $\mu_A : \mathcal{X} \to [0,1]$ nazywamy funkcją przynależności do zbioru rozmytego A. Jego wartość $x \in \mathcal{X}$ jest określany jako stopień przynależności x do A. [1]

Funkcja przynależności określa, w jakim stopniu element x przynależy do zbioru. W zbiorach rozmytych są to wartości z przedziału [0,1].

Aby wygenerować podsumowania lingwistyczne bazy danych korzystamy z podsumowań lingwistycznych jednopodmiotowych w pierwszej i drugiej formie oraz wielopodmiotowych w pierwszych cztereach formach.

2.1. Podsumowania jednopodmiotowe w pierwszej formie [1]

Podsumowanie lingwistyczne jednopodmiotowe w pierwszej formie ma postać:

$$Q\ P\ jest\ S_j\ [T] \tag{2}$$

gdzie
— Q - kwantyfikator absolutny lub względny, reprezentowany przez zbiór rozmyty
— P - podmiot podsumowania
— S_j - sumaryzator reprezentowany przez zbiór rozmyty
— T - miara jakości dla podsumowania.

Ponadto, takie podsumowanie może mieć również postać ze złożonym sumaryzatorem:

$$Q\ P\ jest\ S_1\ AND\ S_2\ AND \ldots\ AND\ S_n[T] \tag{3}$$

2.2. Podsumowania jednopodmiotowe w drugiej formie [1]

Podsumowanie lingwistyczne jednopodmiotowe w pierwszej formie ma postać:

$$Q\ P \text{ będących } W\ jest\ S_j\ [T] \tag{4}$$

gdzie
— W - kwalifikator wyrażony zbiorem rozmytym.

Podobnie, jak w przypadku zdań jednopodmiotowych w pierwszej formie, kwalifikator moze być złożony z kilku zbiorów rozmytych oraz jednocześnie sumaryzator.

2.3. Podsumowania wielopodmiotowe [2]

W podsumowaniach wielopodmiotowych przyjmuje się następujące oznaczenia:
— P_1, P_2 - podmioty podsumowań reprezentowane przez rozłączne podzbiory $\mathcal{D}_1$, $\mathcal{D}_2$ w $\mathcal{D}$
— M_1, M_2 - liczby obiektów w P_1, P_2
— Q - względny kwantyfikator lingwistyczny
— S i W - odpowiednio sumaryzator i kwalifikator lingwistyczny

Pierwsza postać podsumowań wielopodmiotowych ma postać:

$$Q\ P_1 \text{ w porównaniu do } P_2\ jest\ S. \tag{5}$$

Druga postać podsumowań wielopodmiotowych ma postać:

$$Q\ P_1 \text{ w porównaniu do tych } P_2, \text{ które są W, jest S.} \tag{6}$$

Trzecia postać podsumowań wielopodmiotowych ma postać:

$$Q\ P_1, \text{ które są W, w porównaniu do } P_2, \text{ jest S.} \tag{7}$$

Czwarta postać podsumowań wielopodmiotowych ma postać:

$$\text{Więcej } P_1 \text{ niż } P_2 \text{ jest S.} \tag{8}$$

2.4. Funkcje prynależności

W naszym programie wykorzystujemy 3 funkcje przynależności: trapezoidalna, trójkątna oraz gaussowska.

2.4.1. Funkcja trapezoidalna

Funkcja trapezoidalna przyjmuje 4 parametry a, b, c, d, dla których spełniony jest warunek a $\leq$ b $\leq$ c $\leq$ d. Jej wzór jest następujący [1]:

$$\mu_A(x) = \begin{cases} \frac{x-a}{b-a} & \text{gdy } x \in (a,\, b), \\ 1 & \text{gdy } x \in [b,\, c], \\ \frac{d-x}{d-c} & \text{gdy } x \in (c,\, d), \\ 0 & \text{w przeciwnym razie.} \end{cases} \tag{9}$$

2.4.2. Funkcja trójkątna

Funkcja trójkątna jest szczególnym przypadkiem funkcji trapezoidalnej. Przyjmuje ona trzy parametry a, b, c, dla których zachodzi warunek a $\leq$ b $\leq$ c. Te parametry określają punkty „załamania" tej funkcji. Jej wzór jest następujący [7]:

$$\mu_A(x) = \begin{cases} \frac{x-a}{b-a} & \text{gdy } x \in (a,\, b), \\ 1 & \text{gdy } x = b, \\ \frac{c-x}{c-b} & \text{gdy } x \in (b,\, c), \\ 0 & \text{w przeciwnym razie.} \end{cases} \tag{10}$$

2.4.3. Funkcja Gaussowska

Funkcja Gaussowska jest definiowana przez 2 parametry które określają środek funkcji oraz jej szerokość. Wzór jest następujący [6]:

$$\mu_A(x) = e^{(-(\frac{x-\bar{x}}{\sigma})^2)} \tag{11}$$

gdzie
— $\bar{x}$ jest środkiem funkcji,
— σ określa szerokość krzywej Gaussowskiej.

3. Miary jakości

3.1. Miary jakości dla zdań jednopodmiotowych

3.1.1. Degree of truth

Degree of truth to suma przynależności wszystkich rozważanych krotek do podsumowania lingwistycznego. Dla zdań jednopodmiotowych bez kwalifikatora oraz kwantyfikatorów relatywnych wzór wygląda następująco:

$$T_1 = \mu_Q(\frac{r}{m}) \tag{12}$$

natomiast zdań jednopodmiotowych bez kwalifikatora oraz kwantyfikatorów absolutnych:

$$T_1 = \mu_Q(r) \tag{13}$$

gdzie

$$r = \sum_{i=1}^{m} \mu_S(d_i) \tag{14}$$

a m to liczba krotek w bazie danych.

Dla zdań jednopodmiotowych z kwalifikatorem kwantyfikator może być tylko względny, a wzór wygląda następująco:

$$T_1 = \mu_Q(r) \tag{15}$$

gdzie

$$r = \frac{\sum_{i=1}^{m}(\mu_S(d_i) \wedge \mu_W(d_i))}{\sum_{i=1}^{m} \mu_W(d_i)} \tag{16}$$

3.1.2. Degree of imprecision

Degree of imprecision określa stopień precyzyjności sumaryzatora. Dany jest wzorem:

$$T_2 = 1 - \left(\prod_{j=1}^{n} \mathrm{in}(S_j)\right)^{1/n} \tag{17}$$

gdzie $in(S_j)$ to stopień rozmycia wyrażony wzorem $in(s_j) = \frac{|supp(S_j)|}{|X|}$ a z kolei $supp(\cdot)$ oznacza nośnik zbioru rozmytego.

3.1.3. Degree of covering

Degree of covering reprezentuje, stopień, w jakim nośnik sumaryzatora pokrywa się z nośnikiem kwalifikatora. Dany jest wzorem:

$$T_3 = \frac{\sum_{i=1}^{m} t_i}{\sum_{i=1}^{m} h_i} \tag{18}$$

gdzie dla zdań z kwalifikatorem:

$$t_i = \begin{cases} 1 & \text{gdy } \mu_S(d_i) > 0 \ \wedge \ \mu_W(d_i) > 0 \\ 0 & \text{w przeciwnym razie.} \end{cases}$$

$$h_i = \begin{cases} 1 & \text{gdy } \mu_W(d_i) > 0 \\ 0 & \text{w przeciwnym razie.} \end{cases}$$

a dla zdań bez kwalifikatora:

$$t_i = \begin{cases} 1 & \text{gdy } \mu_S(d_i) > 0 \\ 0 & \text{w przeciwnym razie.} \end{cases}$$

$$h_i = 1$$

3.1.4. Degree of appropriateness

Degree of appropriateness definiuje, jak dużo krotek przynależy do sumaryzatora, czyli czy określone podsumowanie jest odpowiednie dla zestawu danych. Dany jest wzorem:

$$T_4 = \left| \prod_{j=1}^{n} r_j - T_3 \right| \tag{19}$$

gdzie

$$r_j = \frac{\sum_{i=1}^{m} g_{ij}}{m} \tag{20}$$

natomiast $g_{ij} = \begin{cases} 1 & \text{gdy } \mu_{S_j}(d_i) > 0 \\ 0 & \text{w przeciwnym wypadku.} \end{cases}$

3.1.5. Length of a summary

Length of a summary określa jakość podsumowania na podstawie złożoności sumaryzatora, czyli im więcej składowych sumaryzatora złożonego, ty niższa wartość tej miary. Dany jest wzorem:

$$T_5 = 2 \cdot \left(\frac{1}{2}\right)^{|S|} \tag{21}$$

gdzie $|S|$ to liczba zbiorów rozmytych z jakich złożony jest sumaryzator.

3.1.6. Degree of quantifier imprecision

Degree of quantifier imprecision przedstawia w jakim stopniu precyzyjny jest kwantyfikator. Im mniejszy nośnik zbioru rozmytego tym wyższa jest jego precyzja. Dany jest wzorem:

$$T_6 = 1 - in(Q) = 1 - \frac{|supp(Q)|}{|\mathcal{X}_Q|} \tag{22}$$

gdzie $|\mathcal{X}_Q| = 1$ dla kwantyfikatora relatywnego, natomiast dla kwantyfikatora absolutnego $|\mathcal{X}_Q| = m$, czyli liczba krotek w bazie danych.

3.1.7. Degree of quantifier cardinality

Degree of quantifier cardinality opisuje stopień precyzji kwantyfikatora, im większa kardynalność kwantyfikatora tym jest on mniej precyzyjny. Dany jest wzorem:

$$T_7 = 1 - \frac{|Q|}{|\mathcal{X}_Q|} \tag{23}$$

gdzie $|\cdot| = clm(\cdot)$ - całka z funkcji przynależności zbioru rozmytego (czyli pole pod jego wykresem).

3.1.8. Degree of summarizer cardinality

Degree of summarizer cardinality opisuje stopień precyzji sumaryzatora, im mniejsza kardynalność sumaryzatora tym jest on bardziej przecyzyjny. Dany jest wzorem:

$$T_8 = 1 - \left(\prod_{j=1}^{n} \frac{|S_j|}{|\mathcal{X}_j|} \right)^{\frac{1}{n}} \tag{24}$$

gdzie n to liczba zbiorów rozmytych z jakich stworzony jest sumaryzator.

3.1.9. Degree of qualifier imprecision

Degree of qualifier imprecision określa, w jakim stopniu precyzyjny jest kwalifikator. Im szerszy nośnik zbioru rozmytego tym niższa jest jego precyzja. Dany jest wzorem:

$$T_9 = 1 - \left(\prod_{j=1}^{x} in(W_{gj}) \right)^{\frac{1}{x}} \tag{25}$$

gdzie $in(W_{gj})$ to stopień rozmycia zbioru rozmytego W_{gj}.

3.1.10. Degree of qualifier cardinality

Degree of qualifier cardinality opisuje stopień precyzji kwalifikatora, im większa jest kardynalność kwalifikatora, tym jest on mniej precyzyjny. Dany jest wzorem:

$$T_{10} = 1 - \left(\prod_{j=1}^{x} \frac{|W_{gj}|}{|\mathcal{X}_{gj}|} \right)^{\frac{1}{x}} \tag{26}$$

3.1.11. Length of qualifier

Length of qualifier wyznacza jakość podsumowania na podstawie złożoności kwalifikatora. Im bardziej złożony kwalifikator, tym jakość podsumowania jest gorsza. Dany jest wzorem:

$$T_{11} = 2 \cdot \left(\frac{1}{2} \right)^{|W|} \tag{27}$$

gdzie $|W|$ to liczba zbiorów rozmytych, z jakich stworzony jest kwalifikator.

3.2. Miary jakości dla zdań wielopodmiotowych

Dla zdań wielopodmiotowych liczymy tylko stopień prawdziwości, czyli miarę T_1.

3.2.1. Degree of truth dla zdań wielopodmiotowych w pierwszej formie [3]

$$T_{1_1} = \left(\frac{\frac{1}{M_1}\Sigma - count(S_{P1})}{\frac{1}{M_1}\Sigma - count(S_{P1}) + \frac{1}{M_2}\Sigma - count(S_{P2})} \right) \tag{28}$$

gdzie
— $\Sigma - count(S_{P1}) = \sum_{i=1}^{m} \{\mu_S(d_i) : d_i \in^* P_1\}$
— $\Sigma - count(S_{P2}) = \sum_{i=1}^{m} \{\mu_S(d_i) : d_i \in^* P_2\}$
— M_1 to liczba krotek reprezentujących podmiot P_1
— M_2 to liczba krotek reprezentujących podmiot P_2

3.2.2. Degree of truth dla zdań wielopodmiotowych w drugiej formie [2]

$$T_{1_2} = \left(\frac{\frac{1}{M_1}\Sigma - count(S_{P1})}{\frac{1}{M_1}\Sigma - count(S_{P1}) + \frac{1}{M_2}\Sigma - count(S_{P2} \cap W)} \right) \tag{29}$$

gdzie
— $\Sigma - count(S_{P2} \cap W) = \sum_{i=1}^{m} \{min(\mu_{S1}(d_i), \mu_W(d_i)) : d_i \in^* P_2\}$

3.2.3. Degree of truth dla zdań wielopodmiotowych w trzeciej formie [2]

$$T_{1_3} = \left(\frac{\frac{1}{M_1}\Sigma - count(S_{P1} \cap W)}{\frac{1}{M_1}\Sigma - count(S_{P1} \cap W) + \frac{1}{M_2}\Sigma - count(S_{P2})} \right) \tag{30}$$

gdzie
— $\Sigma - count(S_{P1} \cap W) = \sum_{i=1}^{m} \{min(\mu_{S1}(d_i), \mu_W(d_i)) : d_i \in^* P_1\}$

3.2.4. Degree of truth dla zdań wielopodmiotowych w czwartej formie [3]

$$T_{1_3} = \left(\frac{\Sigma - count(S_{P1})}{\Sigma - count(S_{P1}) + \Sigma - count(S_{P2})} \right) \tag{31}$$

4. Opis implementacji

Program został stworzony w języku C#. Graficzny interfejs użytkownika został stworzony przy wykorzystaniu Windows Presentation Foundation. Poniżej przedstawiamy uproszczony diagram UML naszego programu.

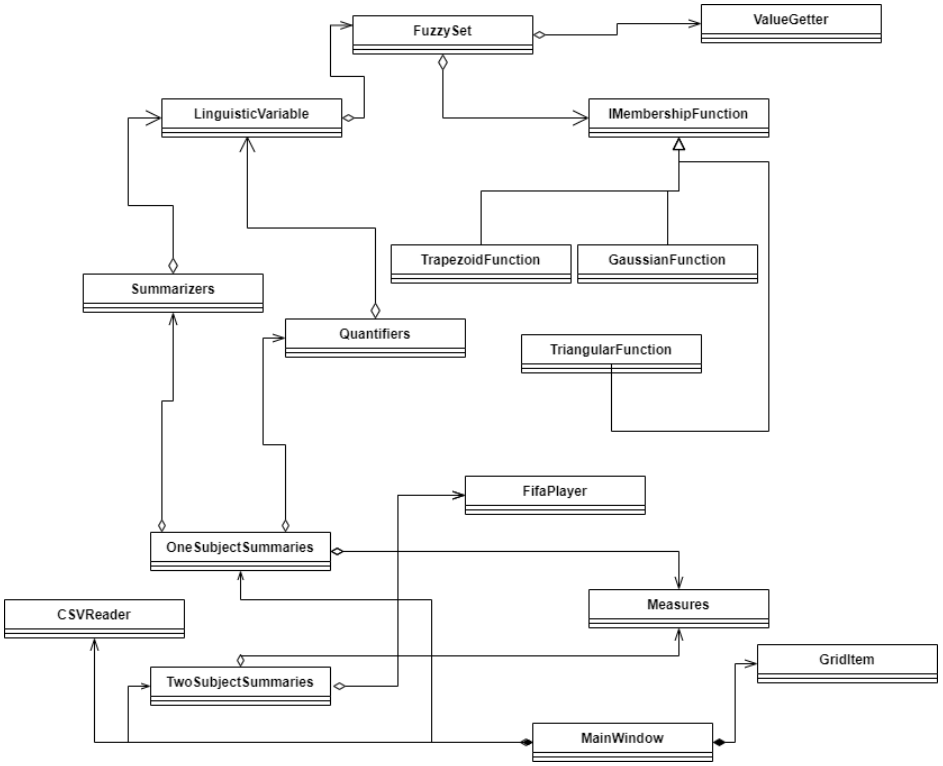

Rysunek 1. Diagram UML.

— Klasa Summarizers przechowuje poszczególne sumaryzatory, np "młody", "wysoki"
— Quantifiers jest klasą odpowiedzialną za kwantyfikatory relatywne oraz absolutne
— CSVReader odpowiada za wczytanie pliku csv z danymi do programu
— FuzzySet to klasa odpowiadająca za zbiór rozmyty
— Klasy TrapezoidFunction, GaussianFunction, TriangularFunction odpowiadają za odpowiednie funkcje przynależności
— FifaPlayer to klasa, która reprezentuje krotkę bazy danych
— LinguisticVariable to klasa reprezentująca zmienną lingwistyczną.
— OneSubjectSummaries oraz MultiSubjectSummaries odpowiadają za generowanie podsumowań kolejno jedno i wielopodmiotowych
— Measures przechowuje odpowiednie funkcje do obliczania miar jakości
— ValueGetter "wyciąga" odpowiednią wartość z danej krotki bazy danych

5. Materiały i metody

5.1. Baza danych

Do przeprowadzania badań oraz do generowania podsumowań wykorzystaliśmy bazę danych dotyczącą piłkarzy z gry FIFA 20. Pochodzi ona ze źródła [5]. Składa się ona z 18278 rekordów posiadających 104 atrybuty. Do naszego projektu skorzystamy z 11. Są to następujące atrybuty:

1. Wiek - *age* - wartość z przedziału [16, 42]
2. Wzrost (w cm) - *height_cm* - wartość z przedziału [156, 205]
3. Waga (w kg) - *weight_kg* - wartość z przedziału [50, 110]
4. Ocena ogólna - *overall* - wartość z przedziału [48, 94]
5. Wykończenie - *attacking_finishing* - wartość z przedziału [2, 95]
6. Dribbling - *skill_dribbling* - wartość z przedziału [4, 97]
7. Podkręcenie piłki - *skill_curve* - wartość z przedziału [6, 94]
8. Długie podania - *skill_long_passing* - wartość z przedziału [8, 92]
9. Sprint - *movement_sprint_speed* - wartość z przedziału [11, 96]
10. Siła strzału - *power_shot_power* - wartość z przedziału [14, 95]

Każda z kolumn jest typu całkowitego.

5.2. Zmienne lingwistyczne

5.2.1. Wiek

Należy zauważyć, że wiek w przypadku zawodnika piłki nożnej oceniany jest w inny sposób niż wiek przeciętnego człowieka.
— *(16-21) bardzo młody*
— *(20-25) młody*
— *(24-32) średni*
— *(31-42) stary*

Etykieta	a	b	c	d
bardzo młody	16	16	18	21
młody	20	22	24	25
średni	24	26	29	32
stary	31	34	42	42

Tabela 1. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Wiek.

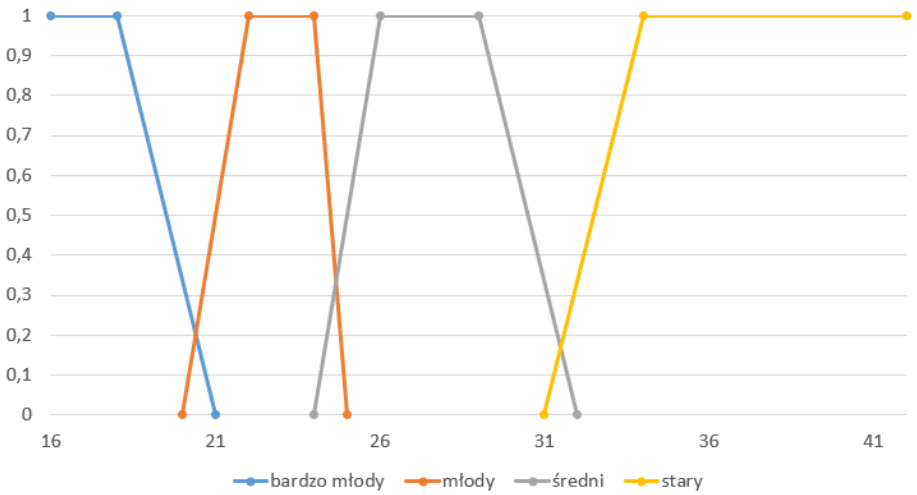

Rysunek 2. Funkcja przynależności (trapezoidalna) dla atrybutu Wiek.

5.2.2. Wzrost

— *(156-166) niski*
— *(164-177) średni*
— *(175-188) wysoki*
— *(186-205) bardzo wysoki*

Etykieta	a	b	c
niski	156	156	166
średni	164	170	177
wysoki	175	182	188
bardzo wysoki	186	205	205

Tabela 2. Przyporządkowane parametry funkcji trójkątnej dla atrybutu Wzrost.

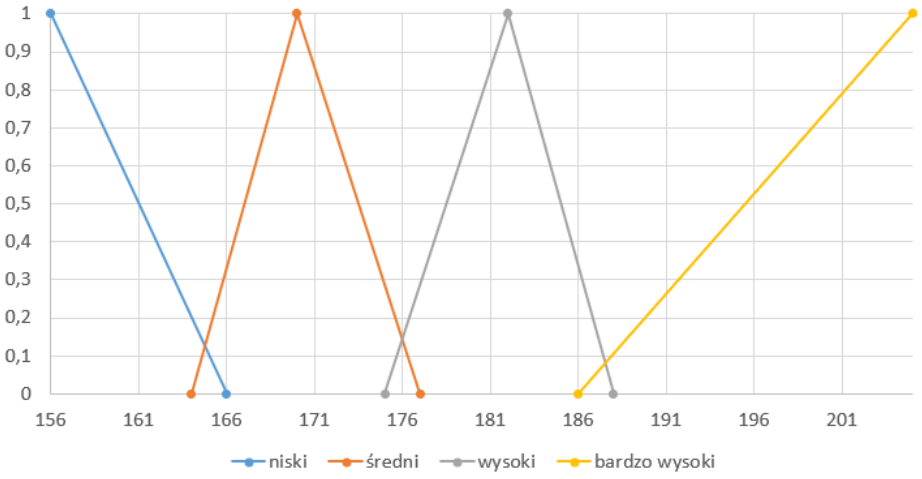

Rysunek 3. Funkcja przynależności (trapezoidalna) dla atrybutu Wzrost.

5.2.3. Waga

— *(50-65) bardzo chudy*
— *(55-85) chudy*
— *(75-105) średni*
— *(95-110) gruby*

Etykieta	$\bar{x}$	σ
bardzo chudy	50	8
chudy	70	8
średni	90	8
gruby	110	8

Tabela 3. Przyporządkowane parametry funkcji gaussowskiej dla atrybutu Waga.

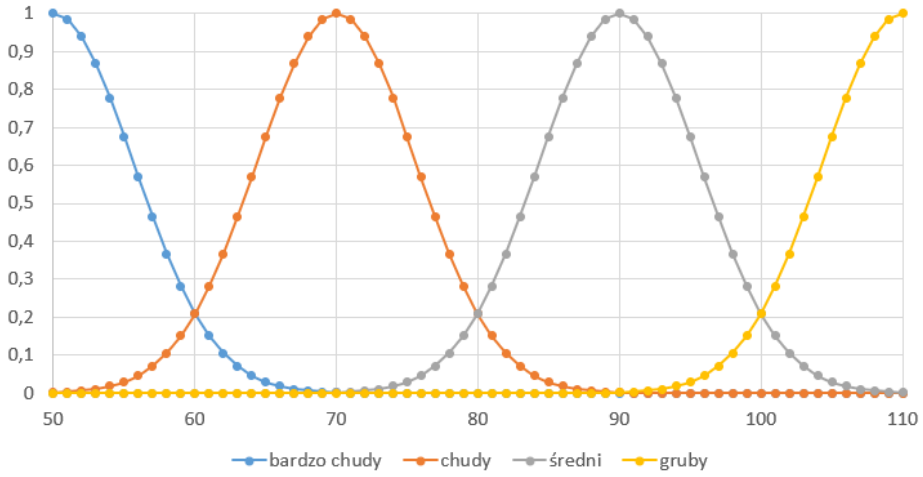

Rysunek 4. Funkcja przynależności (gaussowska) dla atrybutu Waga.

5.2.4. Ocena ogólna

— *(48-65) słaby*
— *(60-75) średni*
— *(70-87) dobry*
— *(85-94) bardzo dobry*

Etykieta	a	b	c	d
słaby	48	48	59	65
średni	60	65	70	75
dobry	70	78	85	87
bardzo dobry	85	90	94	94

Tabela 4. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Ocena ogólna.

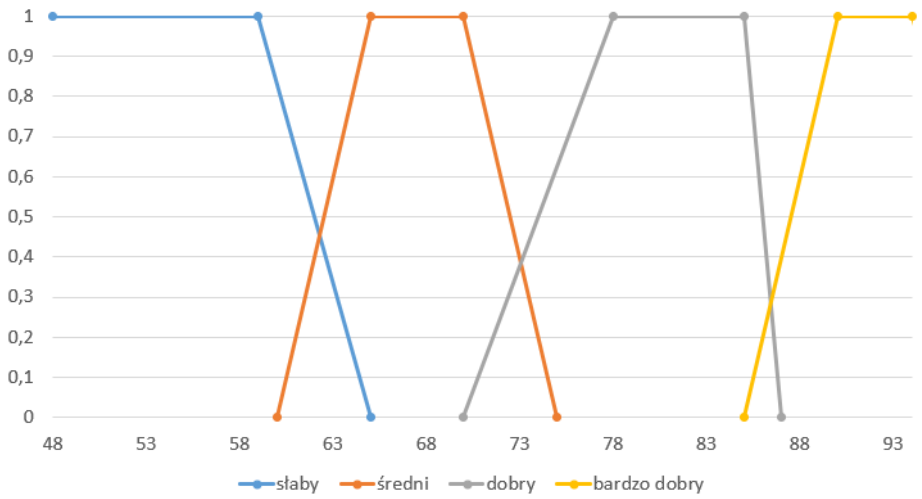

Rysunek 5. Funkcja przynależności (trapezoidalna) dla atrybutu Ocena ogólna.

5.2.5. Wykończenie

— *(2-35) bardzo słabe*
— *(30-60) słabe*
— *(50-80) średnie*
— *(75-87) dobre*
— *(85-95) bardzo dobre*

Etykieta	a	b	c	d
bardzo słabe	2	2	25	35
słabe	30	35	50	60
średnie	50	55	75	80
dobre	75	80	85	87
bardzo dobre	85	90	95	95

Tabela 5. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Wykończenie.

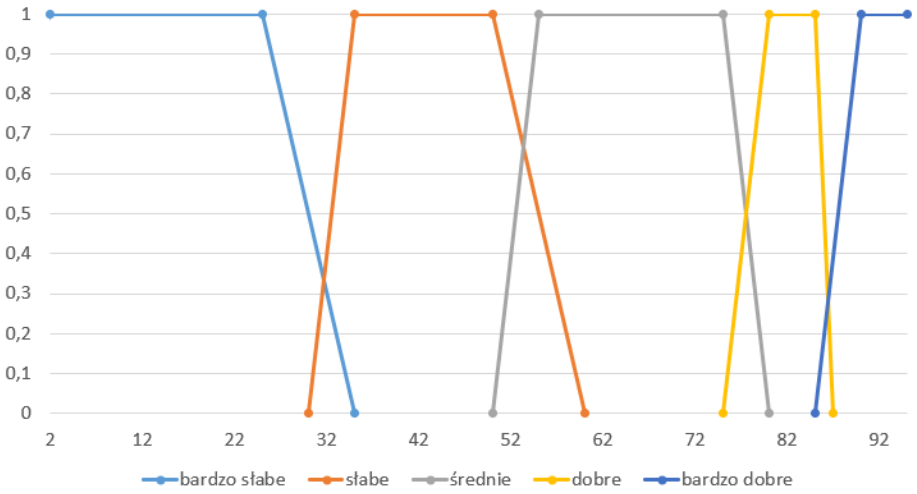

Rysunek 6. Funkcja przynależności (trapezoidalna) dla atrybutu Wykończenie.

5.2.6. Dribbling

— *(4-35) bardzo słaby*
— *(30-60) słaby*
— *(50-70) średni*
— *(68-87) dobry*
— *(85-97) bardzo dobry*

Etykieta	a	b	c	d
bardzo słaby	4	4	25	35
słaby	30	35	50	60
średni	50	55	68	70
dobry	68	73	85	87
bardzo dobry	85	90	97	97

Tabela 6. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Dribbling.

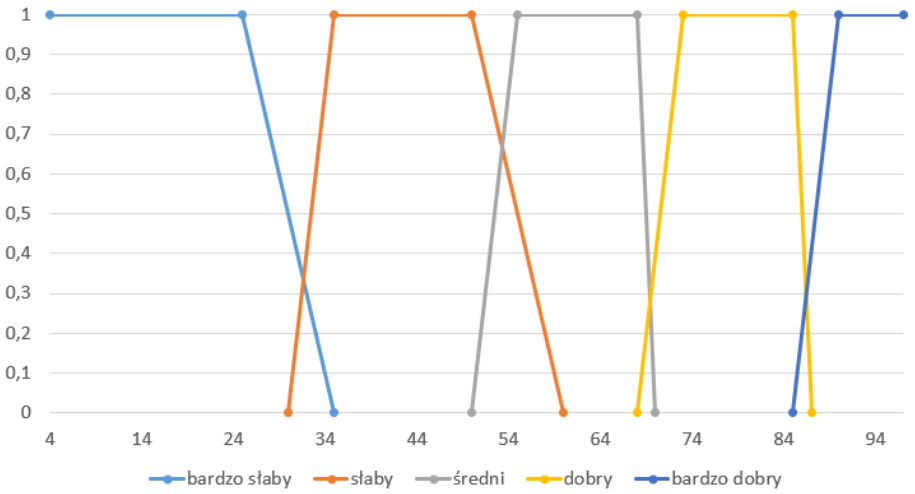

Rysunek 7. Funkcja przynależności (trapezoidalna) dla atrybutu Dribbling.

5.2.7. Podkręcenie piłki

— *(6-35) bardzo słabe*
— *(30-60) słabe*
— *(50-70) średnie*
— *(68-87) dobre*
— *(85-94) bardzo dobre*

Etykieta	a	b	c
bardzo słabe	6	6	35
słabe	20	35	60
średnie	50	60	70
dobre	68	75	87
bardzo dobre	85	94	94

Tabela 7. Przyporządkowane parametry funkcji trójkątnej dla atrybutu Podkręcenie piłki.

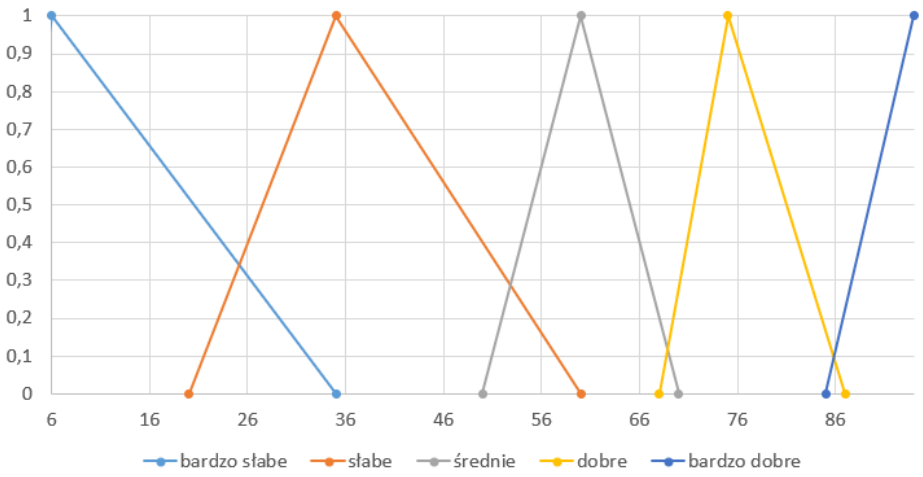

Rysunek 8. Funkcja przynależności (trójkątna) dla atrybutu Podkręcenie piłki.

5.2.8. Długie podania

— *(8-35) bardzo słabe*
— *(30-60) słabe*
— *(50-70) średnie*
— *(68-85) dobre*
— *(82-92) bardzo dobre*

Etykieta	a	b	c	d
bardzo słabe	8	8	25	35
słabe	30	35	50	60
średnie	50	55	68	70
dobre	68	73	80	85
bardzo dobre	82	85	92	92

Tabela 8. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Długie podania.

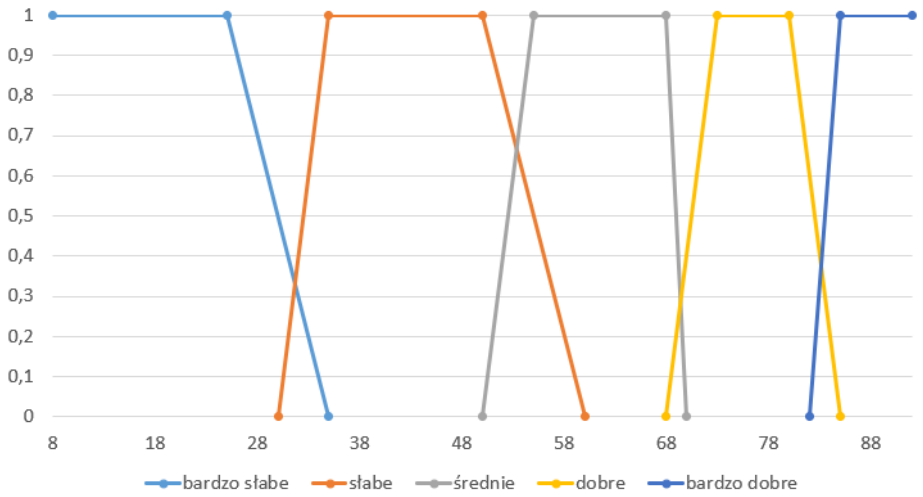

Rysunek 9. Funkcja przynależności (trapezoidalna) dla atrybutu Długie podania.

5.2.9. Sprint

— *(11-35) bardzo wolny*
— *(30-55) wolny*
— *(50-70) średni*
— *(68-86) szybki*
— *(84-96) bardzo szybki*

Etykieta	a	b	c	d
bardzo wolny	11	11	25	35
wolny	30	35	48	55
średni	50	55	68	70
szybki	68	73	80	86
bardzo szybki	84	90	96	96

Tabela 9. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Sprint.

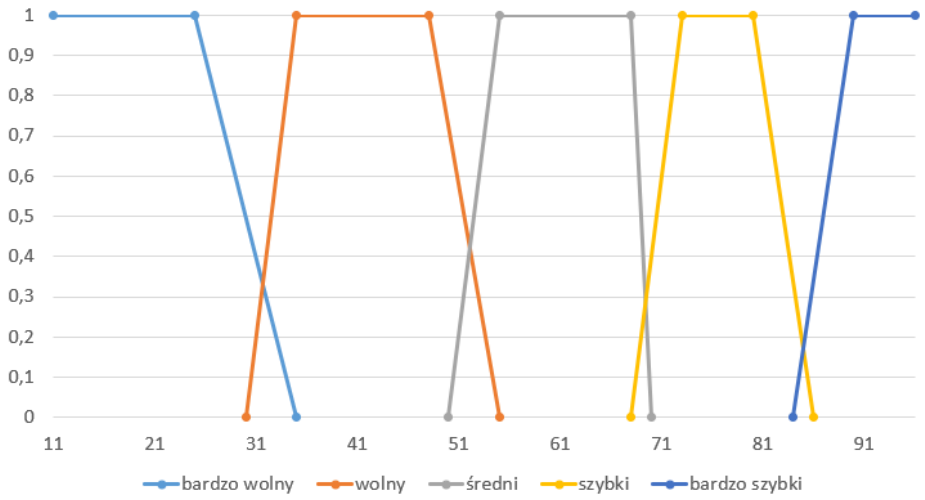

Rysunek 10. Funkcja przynależności (trapezoidalna) dla atrybutu Sprint.

5.2.10. Siła strzału

— *(14-50) słaba*
— *(45-65) średnia*
— *(62-82) duża*
— *(80-95) bardzo duża*

Etykieta	a	b	c	d
słaba	14	14	45	50
średnia	45	50	60	65
duża	62	68	80	82
bardzo duża	80	88	95	95

Tabela 10. Przyporządkowane parametry funkcji trapezoidalnej dla atrybutu Siła strzału.

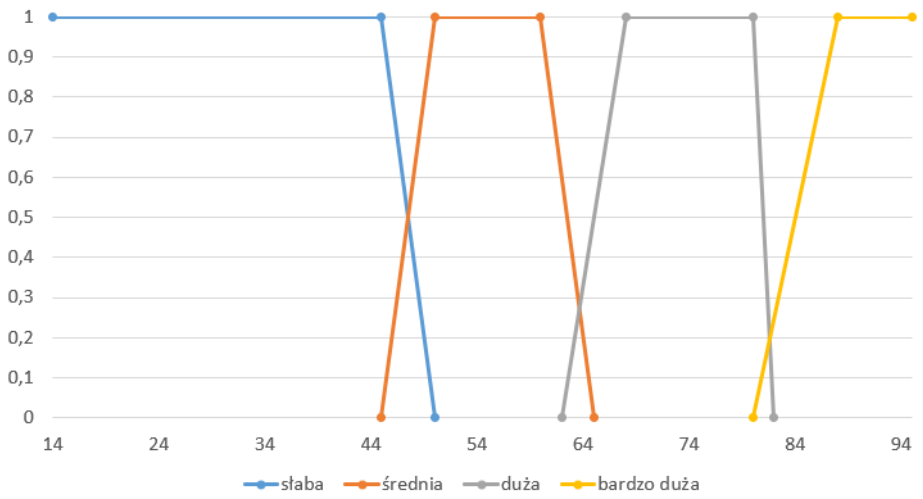

Rysunek 11. Funkcja przynależności (trapezoidalna) dla atrybutu Siła strzału.

5.3. Kwantyfikator względny

Poniżej przedstawiliśmy wartości parametrów oraz wykres funkcji przynależności dla kwantyfikatora względnego. Liczba rekordów w naszej bazie danych wynosi 18278, wykres zawiera się w wartościach [0, 1].

Etykieta	a	b	c	d
prawie nikt	0,000	0,000	0,055	0,164
mniejszość	0,109	0,164	0,383	0,438
połowa	0,410	0,438	0,547	0,574
większość	0,547	0,602	0,821	0,875
prawie wszyscy	0,821	0,903	1,000	1,000

Tabela 11. Przyporządkowane parametry funkcji trapezoidalnej dla kwantyfikatora względnego.

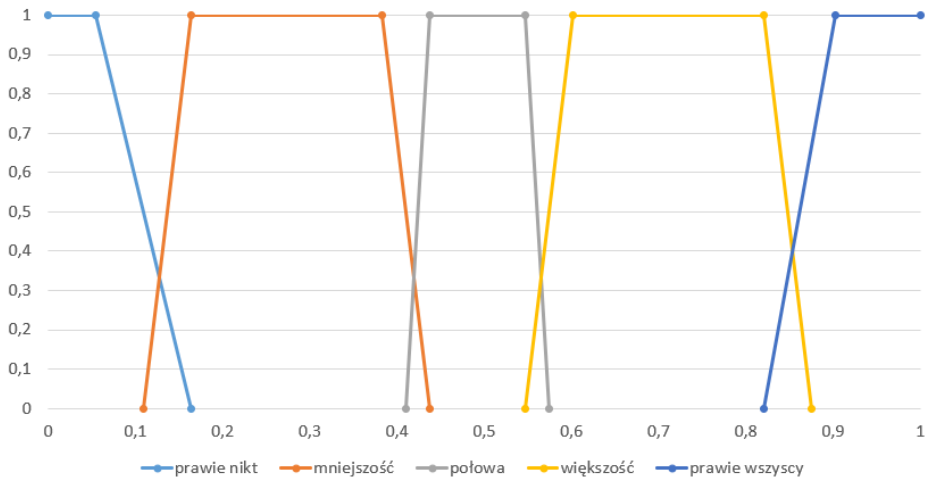

Rysunek 12. Funkcja przynależności kwantyfikatora względnego.

5.4. Kwantyfikator absolutny

Etykieta	a	b	c	d
Około 1000	900	960	1040	1100
Więcej niż 3000	0,109	0,164	0,383	0,438
Mniej niż 3000	0	0	2990	3010
Około 500	450	480	520	550
Około 100	80	90	110	120

Tabela 12. Przyporządkowane parametry funkcji trapezoidalnej dla kwantyfikatora absolutnego.

5.5. Przeprowadzone eksperymenty

Eksperymenty, jakie zdecydowaliśmy przedstawić są następujące:

1. Porównanie miar jakości dla różnych kwantyfikatorów w zdaniach jednopodmiotowych.
2. Porównanie podsumowań z kwalifikatorem oraz bez (zdania jednopodmiotowe w formie pierwszej i drugiej).
3. Porównanie podsumowań z sumaryzatorem oraz złączeniem kilku sumaryzatorów
4. Porównanie miary degree of truth dla różnych typów zdań wielopodmiotowych.

6. Wyniki

6.1. Porównanie miar jakości dla różnych kwantyfikatorów

6.1.1. Zdania jednopodmiotowe w pierwszej formie

W tej części eksperymentu wygenerowaliśmy zdania dla jednego sumaryzatora "average overall". W tabeli oraz na wykresie poniżej zamieściliśmy tylko wyniki dla miar T_1, T_6 oraz T_7, ponieważ pozostałe miary miały stałe wyniki i wynosiły następująco: $T_2 = 0.674, T_3 = 0.684, T_4 = 0, T_5 = 1, T_8 = 0.333, T_9 = 0, T_{10} = 0, T_{11} = 0$

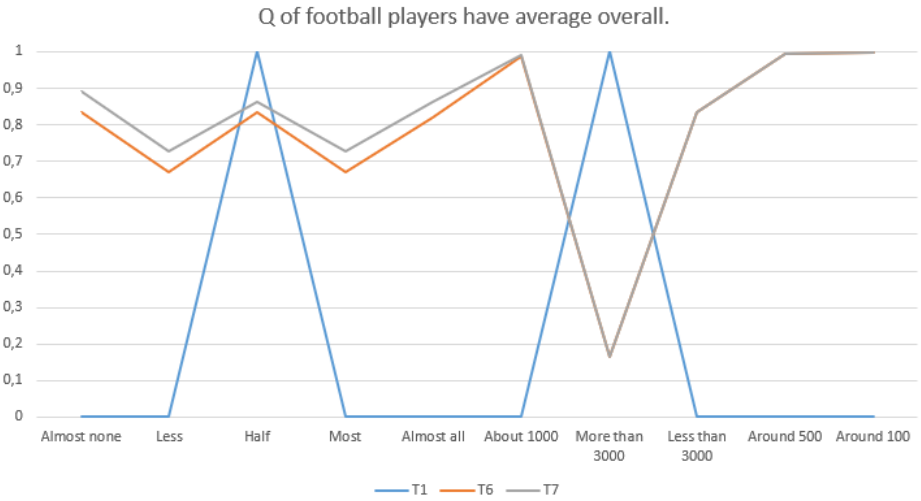

Rysunek 13. Porównanie miar jakości T1, T6 i T7 w zależności od różnych kwantyfikatorów w zdaniu jednopodmiotowym w pierwszej formie.

Kwantyfikator	T_1	T_6	T_7
Almost none	0	0,836	0,89
Less	0	0,671	0,726
Half	1	0,836	0,863
Most	0	0,672	0,726
Almost all	0	0,821	0,862
About 1000	0	0,989	0,992
More than 3000	1	0,164	0,164
Less than 3000	0	0,835	0,836
Around 500	0	0,995	0,996
Around 100	0	0,998	0,998

Tabela 13. Miary T_1, T_6 oraz T_7 dla różnych kwantyfikatorów.

6.1.2. Zdania jednopodmiotowe w drugiej formie

W tej części eksperymentu wygenerowaliśmy zdania dla jednego sumaryzatora "average curve" oraz kwalifikatora "good long passing". W tabeli oraz na wykresie poniżej zamieściliśmy tylko wyniki dla miar T_1, T_6 oraz T_7, ponieważ pozostałe miary miały stałe wyniki i wynosiły następująco: $T_2 = 0.773, T_3 = 0.431, T_4 = 0.073, T_5 = 1, T_8 = 0.5, T_9 = 0.798, T_{10} = 0.294, T_{11} = 1$

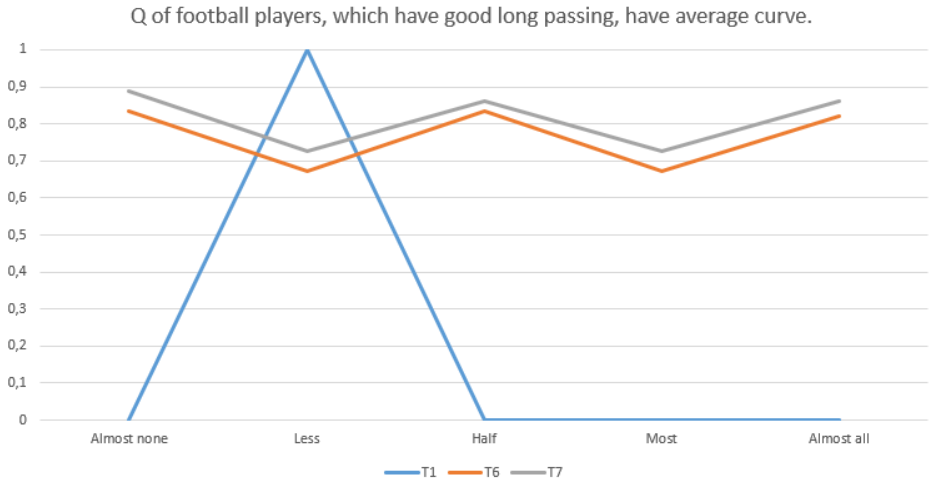

Rysunek 14. Porównanie miar jakości T1, T6 i T7 w zależności od różnych kwantyfikatorów w zdaniu jednopodmiotowym w drugiej formie.

Kwantyfikator	T_1	T_6	T_7
Almost none	0	0,836	0,89
Less	0	0,671	0,726
Half	1	0,836	0,863
Most	0	0,672	0,726
Almost all	0	0,821	0,862

Tabela 14. Miary T_1, T_6 oraz T_7 dla różnych kwantyfikatorów.

6.2. Porównanie podsumowań z kwalifikatorem oraz bez

W tym eksperymencie sprawdziliśmy, jak kwalifikator wpływa na jakość wyników w zdaniach jednopodmiotowych w drugiej formie. Porównania dokonaliśmy na dwóch różnych przypadkach.

W pierwszym przypadku, kwantyfikatorem była etykieta "Most", sumaryzatorem etykieta "average age", a kwalifikatorem "very good overall". Podobnie jak w pierwszym eksperymencie niektóre wartości kilku miar jakości były stałe i wynosiły: $T_2 = 0.692, T_5 = 1, T_6 = 0.672, T_7 = 0,726$ oraz $T_8 = 0.312$. Miary T_9 - T_{11} zależą od kwalifikatora, więc nie były brane pod uwagę w porównaniu.

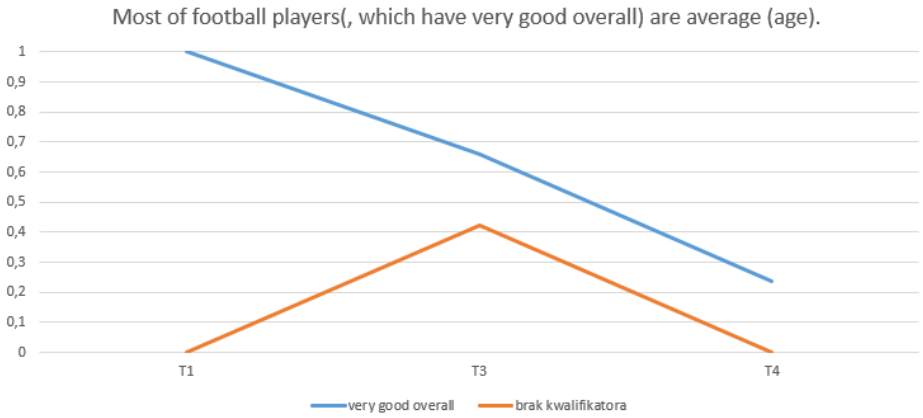

Rysunek 15. Porównanie miar jakości T1, T3 i T4 w zależności od obecności kwalifikatora, sumaryzator złożony z jednej etykiety.

Miara	very good overall	brak kwalifikatora
T1	1	0
T3	0,658	0,421
T4	0,237	0

Tabela 15. Miary T_1, T_3 oraz T_4 w zależności od obecności kwalifikatora.

W drugim przypadku, kwantyfikatorem była etykieta "Almost none", sumaryzatorem etykiety "slow and bad finishing", a kwalifikatorem "weak curve". Wartości miar jakości T_2 oraz $T_5 - T_8$ były stałe i wynosiły: $T_2 = 0.692, T_5 = 0.5, T_6 = 0.836, T_7 = 0,890$ oraz $T_8 = 0.245$. Miary T_9 - T_{11} zależą od kwalifikatora, więc nie były brane pod uwagę w porównaniu.

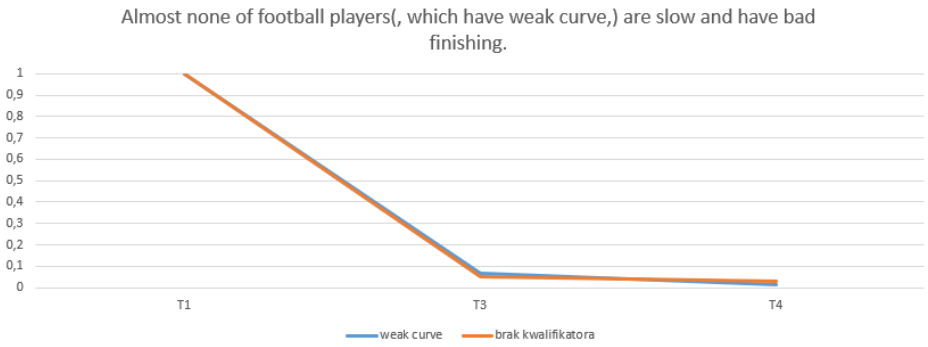

Rysunek 16. Porównanie miar jakości T1, T3 i T4 w zależności od obecności kwalifikatora, sumaryzator złożony z dwóch etykiet.

Miara	weak curve	brak kwalifikatora
T1	1	1
T3	0,068	0,053
T4	0,014	0,029

Tabela 16. Miary T_1, T_3 oraz T_4 w zależności od obecności kwalifikatora.

6.3. Porównanie podsumowań z sumaryzatorem oraz złączeniem kilku sumaryzatorów

W tej sekcji pokażemy porównanie 3 różnych zdań ze stałym kwantyfikatorem oraz kwalifikatorem. Wybrane przez nas sumaryzatory wyglądały następująco:

— S_1 - Average finishing
— S_2 - Average shot power
— S_3 - Average finishing AND average shot power

Podobnie, jak w poprzednich sekcjach, niektóre z miar jakości miały stałe wartości i wynosiły: $T_6 = 0.671, T_7 = 0.726$ oraz $T_9 = T_{10} = T_{11} = 0$ - brak kwalifikatora.

Miara	average finishing	average shot power	AND
T1	0,268	1	0,203
T2	0,677	0,753	0,718
T3	0,465	0,449	0,177
T4	0	0	0,032
T5	1	1	0,5
T8	0,167	0,25	0,209

Tabela 17. Porównanie miar jakości w zależności od sumaryzatora.

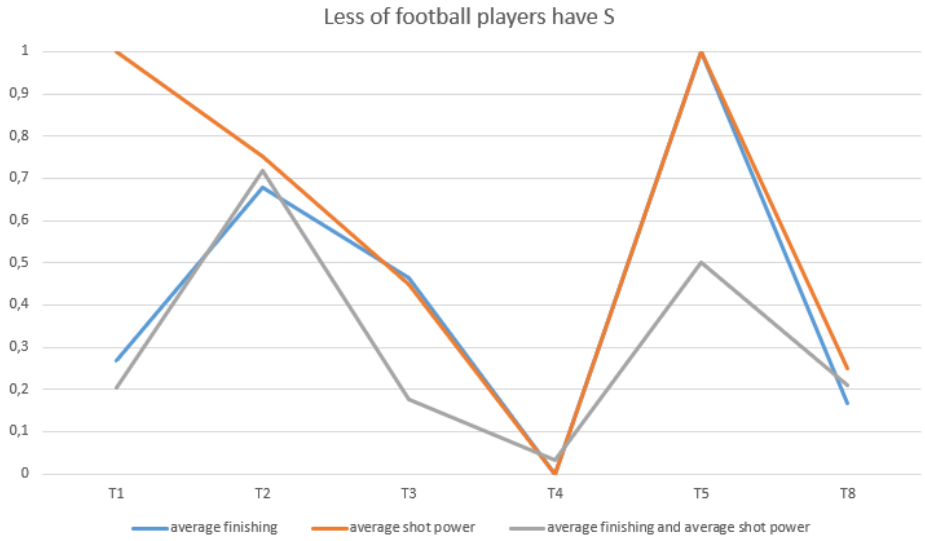

Rysunek 17. Porównanie miar jakości w zależności od sumaryzatora.

6.4. Porównanie miary degree of truth dla różnych typów zdań wielopodmiotowych

W tym badaniu sprawdzaliśmy, jakie są wyniki miary jakości Degree of Truth w zależności od wyboru formy podsumowania wielopodmiotowego. Dla tego eksperymentu:
— S = 'very high'
— W = 'average (age)'
— P1 - Goalkeepers (bramkarze)
— P2 - Midfielders (pomocnicy)
Poniżej przedstawiamy wygenerowane zdania w każdej z form.

1. Almost all of goalkeepers in comparision to midfielders are very high.
2. Almost all of goalkeepers in comparision to those midfielders, who are average (age), are very high.
3. Almost all of those goalkeepers, who are average (age), in comparision to midfielders, are very high.
4. More goalkeepers than midfielders are very high.

Forma podsumowania	T_1
1 forma	1
2 forma	1
3 forma	0.21006
4 forma	0.79485

Tabela 18. Porównanie miary Degree of Truth w zależności od formy podsumowania wielopodmiotowego.

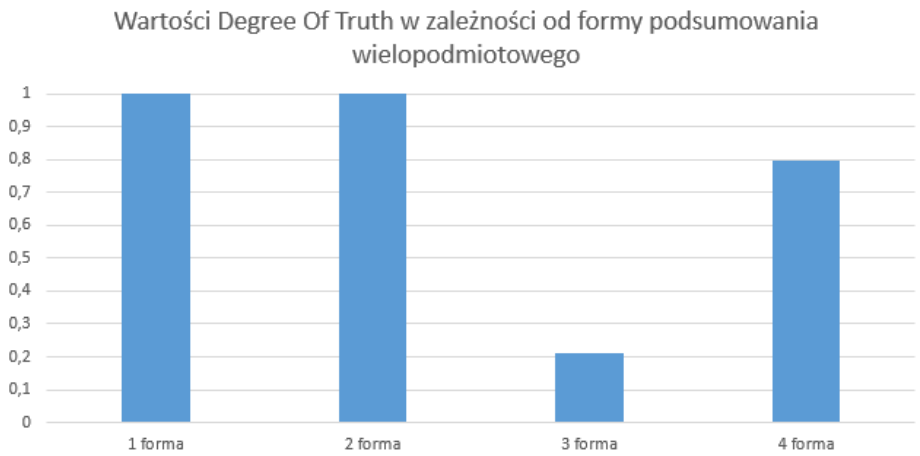

Rysunek 18. Wykres porównujący miary Degree of Truth w zależności od formy podsumowania wielopodmiotowego.

7. Dyskusja

7.1. Wpływ kwantyfikatora na miary jakości w zdaniach jednopodmiotowych

Wartość miary T_1 była różna od 0 tylko dla dwóch kwantyfikatorów na wykresie 13 oraz tylko dla jednego na wykresie 14. Tam, gdzie wartość wynosiła 1, wiemy, że to podsumowanie jest dopasowane do danego kwantyfikatora.

W przypadku miar T_6 oraz T_7, które opisują nieprecyzyjność oraz liczność kwantyfikatora, wartości oscylowały w okolicach wartości 0.8, czyli dosyć wysokie wartości. Dla pierwszego przypadku, tylko dla kwantyfikatora *More than 3000* wartość tych miar była bardzo niska i wyniosła ok. 0,164.

Pozostałe miary, tj. $T_2 - T_5, T_8 - T_{11}$ nie zmieniały swoich wartości, gdyż te miary nie zależą od wybranego kwantyfikatora.

7.2. Wpływ kwalifikatora na miary jakości w zdaniach jednopodmiotowych

W tym eksperymencie widać znaczącą różnicę miary T_1 w pierwszym przykładzie - dla zdania z kwalifikatorem wartość T_1 wyniosła 1, a dla zdania bez kwalifikatora - 0. Również miary T_3 oraz T_4 znacznie się od siebie różniły.

W drugim przykładzie, wszystkie miary T_1, T_3 oraz T_4 miały bardzo podobne wartości. $T_1 = 1$, natomiast T_3 oraz T_4 były bliskie 0.

Miary pozostałe, które nie zostały uwzględnione w wynikach były stałe, gdyż nie zależały od wyboru kwalifikatora, natomiast miary $T_9 - T_{11}$ nie były badane, gdyż bez kwalifikatora nie da się ich obliczyć.

7.3. Porównanie podsumowań z sumaryzatorem oraz złączeniem kilku sumaryzatorów

W tym badaniu największą różnicę możemy zauważyć dla miary T_1 - dla sumaryzatora "average shot power" wartość wyniosła 1, natomiast dla suma-

ryzatora "average finishing" oraz ich złączenia wyniki były bliskie wartości 0.2.

Miara T_2, określająca precyzyjność sumaryzatora największą wartość osiągnęła dla sumaryzatora S_2, lecz złączenie dwóch sumaryzatorów (S_3) dało lepszy wynik niż sumaryzator S_1.

Wartości miary T_3 były bardzo podobne dla sumaryzatorów S_1 i S_2, lecz dla ich złączenia wartość drastycznie spadła. Wartość miary T_4 jest bliska zeru dla wszystkich sumaryzatorów.

Wartość miary T_5 spadła z wartości 1 dla pojedynczych sumaryzatorów do wartości 0.5 dla ich złączenia, gdyż ta miara jest zależna od ilości zbiorów rozmytych, na które składa się sumaryzator.

Miara T_8 dla wszystkich sumaryzatorów zawsze wyniosła około 0.2.

7.4. Porównanie miary degree of truth dla różnych typów zdań wielopodmiotowych

W przypadku podsumowań wielopodmiotowych, liczymy tylko miarę Degree of Truth. Jak można zauważyć na wykresie 18 oraz tabeli 18, wartości dla pierwszej i drugiej formy wyniosły 1, ale dla 3 formy już ok. 0.21. Dla 4 formy wynik wyniósł ok. 0.79.

8. Wnioski

— Lingwistyczne podsumowania baz danych znacznie przyspieszają analizę danych z wieloma atrybutami poprzez generowanie informacji zrozumiałych dla człowieka.
— Im większa ilość krotek w bazie, tym lepsze będą podsumowania bazy danych.
— Najlepiej jest dobrać więcej wąskich przedziałów funkcji przynależności, tak, aby można było uzyskać najlepsze wyniki.
— Miara T_1 jest najważniejsza w porównaniu wygenerowanych podsumowań, lecz lepiej jest porównać również wyniki innych miar jakości
— Etykiety powinny się na siebie nakładać, aby uniknąć pustych obszarów w dziedzinie.
— Część z wygenerowanych przez program komunikatów była do przewidzenia przed wygenerowaniem podsumowań. Teraz jednak możemy stwierdzić to za pomocą formalnej i statystycznej miary.

Literatura

[1] Niewiadomski, Adam. Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions. Akademicka Oficyna Wydawnicza EXIT. Warszawa, 2008. ISBN 978-83-60434-40-6

[2] Niewiadomski, Adam. Zbiory rozmyte typu 2. Zastosowania w reprezentowaniu informacji. Akademicka Oficyna Wydawnicza EXIT. Warszawa, 2019. ISBN 978-83-7837-595-1

[3] Pozyskiwanie wiedzy z relacyjnych baz danych: wielopodmiotowe podsumowania lingwistyczne. [online] [dostęp 04.06.2020] http://cejsh.icm.edu.pl/cejsh/element/bwmeta1.element.desklight-48b6e678-8bdb-4a2b-ab79-77a76631b2e5/c/30.pdf

[4] Treść zadania 2. [online] [dostęp 04.06.2020] https://ftims.edu.p.lodz.pl/pluginfile.php/132360/mod_resource/content/6/ksr-projekt2-2019.pdf

[5] Źródło bazy danych zawodników z gry FIFA 20. [online] [dostęp 04.06.2020] https://www.kaggle.com/stefanoleone992/fifa-20-complete-player-dataset

[6] https://pracownik.kul.pl/files/31717/public/Funkcje_przynaleznosci.pdf [dostęp 07.05.2020]

[7] http://ii.uwb.edu.pl/rudnicki/wp-content/uploads/2016/02/P07.pdf [dostęp 08.05.2020]